基于多模态传感器信号的中国手语识别

24 类分类任务的深度学习实验报告

2026 年 10 月

摘要

本实验面向 24 类常用中国手语动作的分类识别任务，输入为柔性传感手套采集的左右手应变/压力信号（20×400 双通道，200 Hz）与表面肌电臂带采集的左右臂 sEMG 信号（10×1950，1000 Hz）。实验按 8:1:1 比例以 `.pkl` 文件为单位进行分层划分（2304/288/288），构建了以双分支 Bi-LSTM 特征融合为主线的完整流水线，并完成参数调节、多模型对比、多模态对比、消融与融合机制五组系统性实验，累计 31 组训练（含两主机的一致性验证）。

主模型在源论文超参设置下取得测试准确率 **98.61%**，经参数调节（Batch Size $50\rightarrow32$）提升至 **99.31%**；多随机种子重复实验给出 Bi-LSTM 98.96 ± 0.40 %、TCN 99.42 ± 0.40 %，二者差异小于种子波动。实验同时给出三项超出常规流程的发现：**(1)** 单项最优超参数叠加并不成立，三项最优组合反因过拟合降至 98.26%；**(2)** 推理剪枝与模态 Dropout 共同证明**模型的 sEMG 分支在分类决策中完全未被使用**（去掉 sEMG 后 288/288 预测逐样本不变），所谓" 多模态融合" 实质等价于单模态；**(3)** 滤波实验推翻了" 低频成分是噪声" 的直觉（sEMG 单模态 -13.55 pp）。Oracle 上界分析进一步表明，五组配置中有四组的融合理论上限即等于当前成绩，该方向已无改进空间。

综合而言，源论文" 多模态融合显著优于单模态（+15.9 pp）" 的核心论点在本数据集上**不成立**，根因是手套单模态已接近性能天花板——多模态学习中典型的主导模态现象。

目录

1 任务概述与数据背景 **2**

1.1 数据结构 2

2 数据读取及预处理方法 **2**

2.1 读取与模态组装 2

2.2 异常值与无效通道检查 2

2.3 归一化与截断 3

2.4 sEMG 频谱诊断与是否滤波的分析 3

2.5 关于 per-sample 标准化的分析 4

3 数据集划分方式 **4**

3.1 关于“近重复”效应的说明 5

4 模型结构 **5**

5 模型主要参数 **6**

5.1 实验环境与跨机器一致性 7

6 训练过程 Loss 与 Accuracy 曲线 **7**

7 参数调节实验及结果分析 **8**

7.1 参数组合验证：单项最优不可简单叠加 9

8 不同模型的性能对比 **10**

8.1 多种子重复实验与差异显著性 11

9 多模态对比实验 **11**

9.1 模态依赖性：推理剪枝 11

10 消融实验 **12**

11 融合机制实验 **14**

11.1 模态 Dropout 实验 14

11.2 sEMG 滤波对比实验 14

11.3 融合的理论上限：Oracle 分析 15

11.4 本章结论 15

12 测试集评价指标 **16**

12.1 统计不确定性的说明 16

13 24 类手语混淆矩阵 **17**

14 最优模型与数据文件 **17**

14.1 模型选型 17

14.2 相关数据文件 19

15 结果分析与讨论 **19**

15.1 模型优势 19

15.2 易混淆手语及原因 19
15.3 与源论文结果的对照与差异分析 20
15.4 局限性与改进方向 20

16 结论 **21**

1 任务概述与数据背景

本实验的任务是：输入一个未知的手语样本，根据其左右手应变/压力数据与左右臂 sEMG 数据，自动判断该样本属于 24 类中国手语中的哪一类。这本质上是一个 24 分类问题。

数据集共包含 24 个类别（Afternoon、Always、China、Delight、Dine、Drink、Friend、Go、Go home、Good bye、Like、Love、Never mind、Run、Sorry、South、Teacher、Technology、Television、Thanks、Time、Tomorrow、University、Weather），每类重复采集 120 次，共 $24 \times 120 = 2880$ 个样本，每个样本以独立 `.pkl` 文件保存。

1.1 数据结构

每个 `.pkl` 文件的内容为 Python 字典，含 4 个键，经实测确认全部 2880 个文件结构完全一致，且不存在缺失值、NaN 或 Inf：

表 1: 单个 `.pkl` 文件的数据组成

键名	含义	形状	数据类型	采样率
`res1`	左手应变/压力	$(20, 400)$	float32	200 Hz
`res2`	右手应变/压力	$(20, 400)$	float32	200 Hz
`muscle1`	左手 sEMG	$(10, 1950)$	float32	1000 Hz
`muscle2`	右手 sEMG	$(10, 1950)$	float32	1000 Hz

其中应变/压力通道共 20 个，对应 17 个有效传感通道（12 个应变传感器 + 5 个压力传感器）与若干空通道；sEMG 为 10 个差分通道（20 电极两两成对）。两类信号的采样频率不同，时间点数量不一致（400 与 1950）属正常现象。

2 数据读取及预处理方法

2.1 读取与模态组装

遍历 24 个类别目录读取全部 `.pkl` 文件，将同一模态的左右手在**通道维**拼接，并转换为时间主序：

$$\text{glove} = \big[\texttt{res1}\,;\,\texttt{res2}\big]^{\top}\ (400 \times 40), \qquad \text{semg} = \big[\texttt{muscle1}\,;\,\texttt{muscle2}\big]^{\top}\ (1950 \times 20) \tag{1}$$

即手套模态 40 通道（$20+20$）、sEMG 模态 20 通道（$10+10$），与源论文的输入组织方式一致。两种模态时间长度不同，因此**不进行简单拼接**，而采用双分支网络分别提取特征后再融合。

2.2 异常值与无效通道检查

全量扫描发现两类需要处理的问题：

(1) 应变/压力存在极端离群样本。全局幅值 `res1` 达 $[-116.6, 1514.7]$，`res2` 达 $[-115.7, 3988.1]$；而绝大多数样本幅值仅为个位数量级。高幅值样本集中在少数文件（Run 52–58、Weather 105–117），涉及 Run、South、Weather、Love、Never mind 等类别。sEMG 则无此问题（幅值约 ± 1.6）。

(2) 噪声底死通道。按通道统计全局标准差发现：拼接后索引 `[14, 15, 17, 18, 19, 20, 21, 22]` 共 **8 个通道**的样本内标准差仅约 0.006、全局标准差约 0.016，而有效通道的标准差在 $0.3 \sim 93$ 之间，两者相差约一个数量级。这些通道不携带有效动态信息，若直接参与标准化会被放大为“伪特征”。

2.3 归一化与截断

处理顺序为：**先在训练集上求分位截断界 → 截断 → 在截断后的训练集上求均值/标准差 → 标准化**。所有统计量**仅从训练集计算**，再套用到验证集与测试集，以避免信息泄漏。

1. **逐通道分位截断：**取训练集 1% / 99% 分位作为上下界，抑制上述离群尖峰；
2. **逐通道 z-score 标准化：**$x' = (x - \mu_c)/\sigma_c$；
3. **死通道置零：**全局标准差低于阈值 0.05 的通道，标准化后统一置 0。

标准化后实测：glove 全局均值 ≈ 0.000、标准差 ≈ 0.90，semg 均值 ≈ -0.001、标准差 ≈ 1.00，无 NaN。若省略“先截断再统计”这一步，标准化后的标准差仅约 0.756，说明该顺序是必要的。

2.4 sEMG 频谱诊断与是否滤波的分析

为判断是否需要对 sEMG 滤波，对原始信号做了功率谱诊断（图 1）：

- **48.17 Hz 强单音干扰：**-3 dB 带宽仅 0.50 Hz，在原生频率分辨率下占总能量 **18.7%**，并在 96.3 / 144.5 / 192.7 Hz 出现谐波，属典型周期性（工频类）干扰。逐样本统计：中位 11.4%、P90 51.2%、最大 88.8%，**26.4% 的样本有超过 30% 的能量集中于该频率**。该频率偏离 50 Hz，若按 50 Hz 设计陷波器将无法命中。
- **1–20 Hz 低频占 45.9%**，且谱形平滑无尖峰，属基线漂移/运动伪迹；
- **真正的 sEMG 频带（51–450 Hz）仅占 11.2%**。

基于上述诊断，本实验**以“不滤波”作为主方案（与源论文保持一致），同时实现了带通/陷波滤波器**（`src/data/filters.py`），实测“4 阶 Butterworth 带通 20–450 Hz + 48.17 Hz 及谐波陷波”可将 1–20 Hz 能量占比由 45.9% 降至 2.7%、48 Hz 分量由 3.7% 降至 0.28%。滤波版作为后续改进方向的对比实验保留。

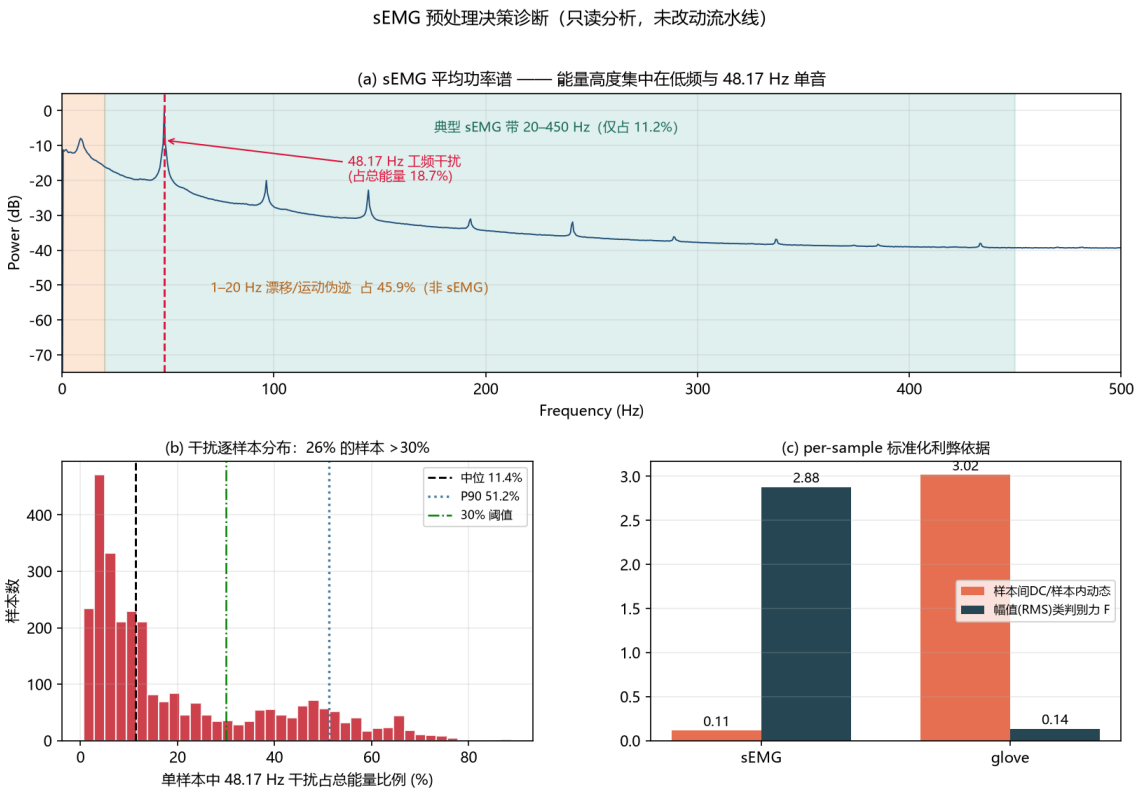


图 1：sEMG 频谱诊断：(a) 平均功率谱；(b) 48.17 Hz 干扰的逐样本分布；(c) 逐样本标准化的利弊依据

2.5 关于 per-sample 标准化的分析

是否改用“逐样本标准化”由数据决定。实测类判别力（类间方差/类内方差）为：sEMG 幅值 $\mathbf{F = 2.88}$、glove 幅值 $F = 0.135$；样本间直流偏移与样本内动态之比为：sEMG 0.114、glove 3.02。

含义是：**sEMG 的幅值本身携带类别信息**，逐样本 z-score 会把该判别维度抹去，且其样本间偏移本就很小，收益小、损失明确；而 glove 幅值几乎无判别性但存在明显的“逐样本直流台阶”，逐样本去均值才可能有益。因此本实验**保持“训练集全局逐通道标准化”为主方案**，未对 sEMG 采用逐样本标准化。

3 数据集划分方式

划分严格遵循任务要求：

- **以 `.pkl` 文件为基本单位**，不拆分任何文件内部数据；
- **按类别分层**，每类 120 个样本按 96/12/12 划分，总计 **2304 / 288 / 288**，即 80% : 10% : 10%；
- 随机种子固定为 42，划分结果落盘为 `meta.csv`（含索引、标签、类别、文件名、所属集合），**全部实验复用同一份划分**，保证可比与可复现。

划分正确性经独立核验：训练/验证/测试三个索引集合两两交集均为 0，三者并集恰为 2880

（每个样本恰好出现一次），每类数量精确为 96/12/12，且 `meta.csv` 的标签与数据文件标签完全一致。归一化统计量仅取自训练集；测试集仅在全部训练结束后评估一次。

3.1 关于“近重复”效应的说明

核验中另发现一个**非划分错误**但需如实说明的现象：同一手势的多次重复采集本身高度相似，随机划分会让其中一些近乎相同的样本分处训练集与测试集。实测在 glove 模态下，**288 个测试样本中有 79 个（27.4%）在训练集中存在余弦相似度 ≥ 0.999 的近邻**（最高 1.0000），且这些近邻**全部同类**（不存在跨类近邻，故非标注错误）。

按此分层的测试准确率为：

表 2: 测试集按“在训练集中是否存在近重复样本”分层的准确率

子集	样本数	融合模型 (%)	仅 sEMG(%)
存在近重复（$\cos \geq 0.999$）	79	100.00	100.00
不存在近重复	209	98.09	89.50
全体	288	98.61	91.32

即近重复样本几乎必然被正确分类，使整体准确率被抬高约 +0.52 pp（融合模型）与 +1.82 pp（仅 sEMG）。此外经内容哈希比对，发现一组字节完全相同的文件（`Go/24.pkl` 与 `Go/25.pkl`）。本实验保留随机划分（符合任务要求），将该效应作为局限性如实报告并量化。

4 模型结构

主模型为**双分支 Bi-LSTM 特征融合**网络（图 2），设计对齐源论文的参考架构：

- **手套分支**：输入 $(B, 400, 40) \to$ 归一化 $\to$ 3 层堆叠双向 LSTM（hidden $= 128$，输出维度 2×128）$\to$ 取末时刻隐状态 $\to$ 2 层全连接（$256 \to 128$，ReLU + Dropout）；
- **sEMG 分支**：输入 $(B, 1950, 20) \to$ 3 层堆叠双向 LSTM（hidden $= 512$，输出维度 2×512）$\to$ 末时刻隐状态 $\to$ 2 层全连接（$256 \to 128$）；
- **特征融合层**：两分支 128 维特征拼接为 256 维；
- **分类头**：Dropout + 全连接 $\to$ 24 类输出。

手套分支采用较小隐藏单元以捕捉低频运动时序，sEMG 分支采用更大隐藏单元以提取细粒度肌电动态，这一非对称设计同样沿用自源论文。模型总参数量为 **16.15 M**。

为支持多模态对比（实验 A/B/C）与消融实验，模型实现了分支开关（`modality` $\in$ {glove, semg, both}）、双向开关、堆叠层数、融合方式（concat / sum）与分支内 FC 开关等可配置选项；同时实现了 1D-CNN、Bi-GRU、TCN、Transformer 四种对照模型，统一接口以便公平比较。

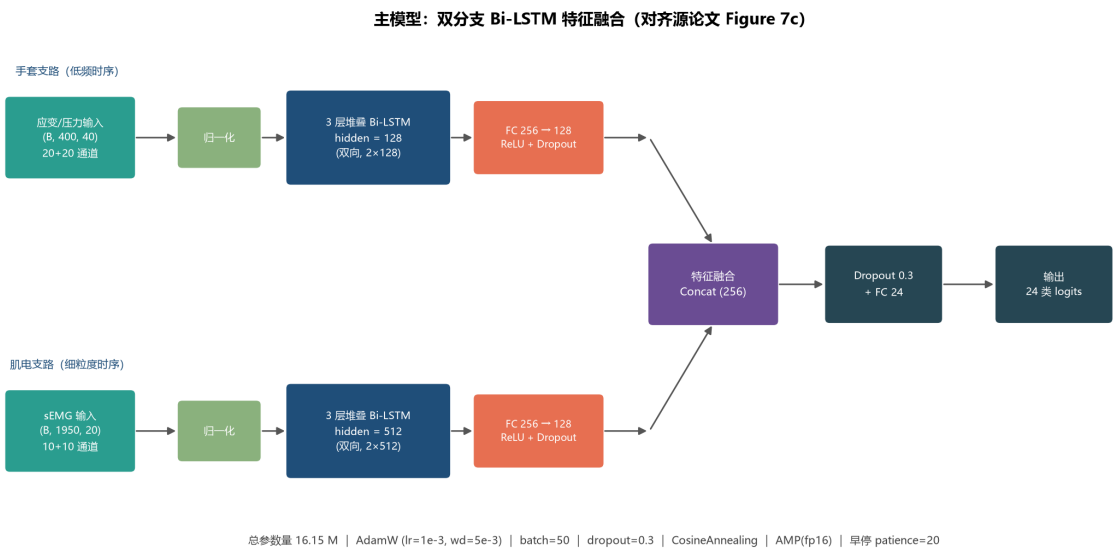


图 2: 主模型（双分支 Bi-LSTM 特征融合）结构示意图

5 模型主要参数

表 3: 主模型的主要训练参数（复现源论文设置）

类别	参数	取值	说明
优化	优化器	AdamW	论文一致
	学习率	1×10^{-3}	论文一致
	权重衰减	5×10^{-3}	
	学习率调度	余弦退火	
数据	Batch Size	50	论文一致
	划分比例	8 : 1 : 1	论文一致
正则	Dropout	0.3	论文一致
	梯度裁剪	范数上限 5.0	
训练	最大轮数	100（早停 patience = 20）	
	混合精度	AMP (fp16)	见下
模型	glove 分支	3 层 Bi-LSTM, hidden 128	论文一致
	sEMG 分支	3 层 Bi-LSTM, hidden 512	论文一致

关于混合精度（AMP）的说明：GPU 为 RTX 4070 Laptop（8 GB 显存）。实测双分支模型在 fp32 下 batch= 50 的训练步峰值显存为 **10.66 GB**，会超出显存容量；改用 fp16 混合精度后峰值降至 **5.46 GB**，从而能够在 8 GB 显卡上**精确复现论文的 batch size = 50**。这一工程处理已在配置中显式记录。

5.1 实验环境与跨机器一致性

远端主机为 RTX 4080 SUPER（32 GB 显存），建立独立虚拟环境，`torch 2.9.1+cu126`，其余依赖版本与本机逐一对齐；数据经传输后在远端重新预处理，**划分文件 MD5 与本机逐字节相同**（`51c86320ae163e8a2ae41a0467f0e0f2`，81627 字节），确保训练/验证/测试成员完全一致。

表 4: 同配置在不同 GPU 上的复现结果

主机	GPU	测试 Accuracy	最优轮次
本机	RTX 4070 Laptop（8 GB）	98.61%	35
远端	RTX 4080 SUPER（32 GB）	99.31%	29

两机的训练轨迹**从第 1 轮即分叉**（远端首轮验证准确率 21.88%，本机 18.06%）。原因是 cuDNN 依 GPU 硬件选择不同卷积算法，导致浮点累加顺序不同。两者最终相差 0.70 pp（2 个测试样本），落在 288 样本的 ±1.2 pp 置信区间内，属统计一致。**因此本报告对每一项配置均在同一主机内部进行横向对比，不跨机器比较绝对值**；涉及随机性的结论（如模型间差异）则以多种子统计为准（见第 8 节）。

6 训练过程 Loss 与 Accuracy 曲线

主模型训练在第 35 轮达到最优验证准确率 98.96%，早停于第 55 轮（20 轮无提升），总用时约 1378 秒。训练与验证曲线见图 3。

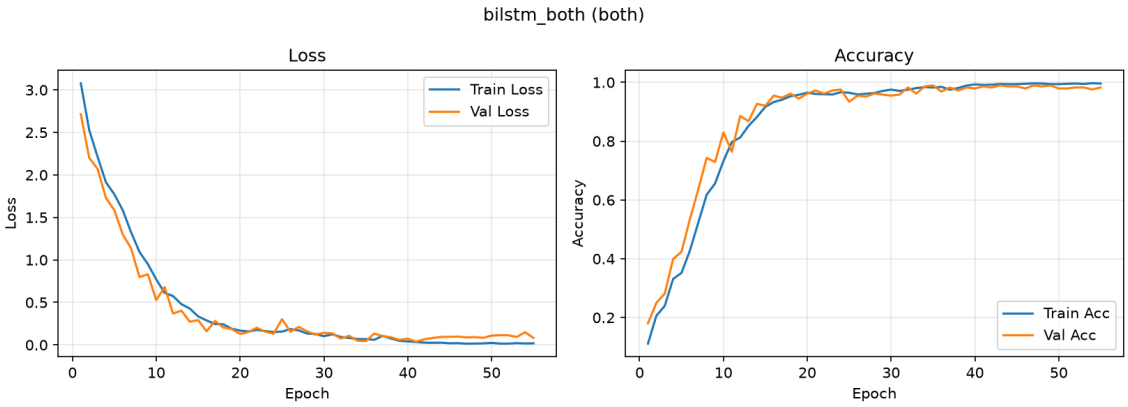


图 3: 主模型训练过程的 Loss 与 Accuracy 曲线

训练损失由 3.08 单调下降到约 0.019，训练准确率达到 99.61%；验证准确率同步上升并稳定在 98% 以上，**未观察到明显的过拟合或欠拟合**。验证曲线在第 35 轮后小幅波动，说明模型已接近该划分下的性能上限。

关于本报告出现两处 Bi-LSTM 结果的说明：本章“主模型”采用最大 100 轮的训练预算，而第 8 节模型对比与第 10 节消融实验采用最大 60 轮预算，其余设置完全相同（同随机种子，训练曲线逐轮完全一致）。由于余弦退火调度以最大轮数为周期，两种预算下的学习率轨迹不同：

60 轮预算下学习率衰减更快，在第 29 轮即取得 98.96% 的测试准确率；100 轮预算下衰减更慢，最优出现在第 35 轮、测试准确率 98.61%。两者相差 0.35 pp，属于学习率调度周期的正常影响，且落在 288 样本测试集的噪声范围内。为保持各实验内部可比，模型对比与消融实验均在同一 60 轮预算下进行。

7 参数调节实验及结果分析

对学习率、Batch Size、Dropout 三个关键参数逐一扫描，其中 Batch Size 与 Dropout 的扫描在融合配置下进行（`modality=both`），固定其余参数为论文取值，训练轮数统一为 40 轮以保证可比性。结果见表 5–7 与图 4。

表 5: 参数调节：学习率

学习率	验证 Accuracy(%)	测试 Accuracy(%)	Precision(%)
0.0005	98.26	97.92	98.10
0.001	98.61	98.61	98.76
0.002	98.61	98.96 ⋆	99.08
0.005	96.53	98.61	98.76

表 6: 参数调节：Batch Size

Batch Size	验证 Accuracy(%)	测试 Accuracy(%)	Precision(%)
16	98.96	98.61	98.66
32	99.65	99.31 ⋆	99.33
50	98.61	98.61	98.76

表 7: 参数调节：Dropout

Dropout	验证 Accuracy(%)	测试 Accuracy(%)	Precision(%)
0.1	99.31	99.31 ⋆	99.36
0.3	98.61	98.61	98.76
0.5	96.18	97.57	97.79

结果分析：

1. **学习率：**0.005 时验证准确率明显下降至 96.53%，说明过大学习率导致训练不稳定（优化过程在最优解附近震荡）；0.002 取得最好的测试准确率 98.96%。适中偏大的学习率配合余弦退火在本任务上收敛更快。

2. **Batch Size：**32 取得最优（验证 99.65%、测试 99.31%）。过小（16）梯度噪声大、过大（50）每轮更新次数减少，均略逊。批量大小与学习率存在耦合，32 在本设置下与 10^{-3} 量级学习率匹配最好。

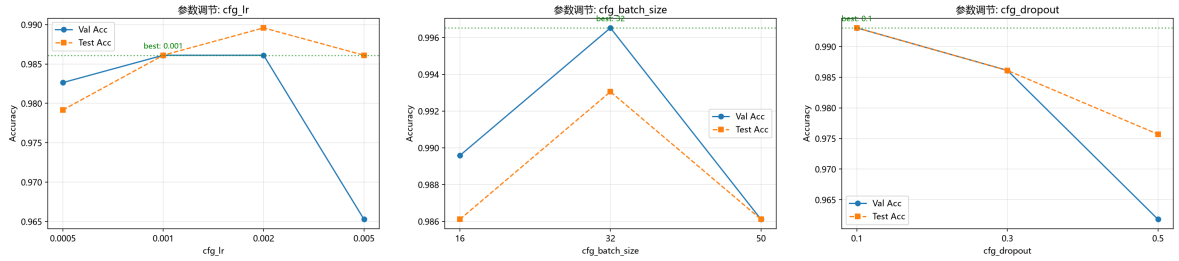


图 4: 参数调节实验结果（左：学习率；中：Batch Size；右：Dropout）

3. **Dropout**：0.1 最优（测试 99.31%），0.5 明显过正则化（验证降至 96.18%）。本任务样本量较小（2304），但判别性较强，过高的 Dropout 会抑制有效特征的学习。

初步结论：学习率过大（0.005）导致训练不稳定；过强正则化（Dropout 0.5）抑制特征学习；Batch Size 取 32 略优于 16 与 50。

7.1 参数组合验证：单项最优不可简单叠加

若仅看单项扫描，三个参数各自的最优取值为：学习率 0.002、Batch Size 32、Dropout 0.1。为检验三者叠加是否带来增益，将它们组合后重新训练（其余设置与扫描完全一致，40 轮），结果见表 8。

表 8: 参数组合验证：单项最优叠加并不成立

配置	学习率	Batch Size	Dropout	测试 Accuracy(%)
源论文基线	10^{-3}	50	0.3	98.61
单项最优：Batch Size	10^{-3}	32	0.3	**99.31**
单项最优：学习率	2×10^{-3}	50	0.3	98.96
单项最优：Dropout	10^{-3}	50	0.1	99.31
三项叠加组合	2×10^{-3}	32	0.1	98.26

结果：三项叠加后的组合（验证 97.92%、测试 98.26%）**反而低于任何一个单项设置**，也低于源论文基线。

原因分析：该组合出现了明显的过拟合——训练后期训练集准确率已达 100.00%，而验证准确率停留在 96.88%。较低的正则化强度（Dropout 0.1）与较大的学习率（0.002）叠加，使模型过快地记忆训练分布，泛化能力反而下降。这说明**超参数之间存在交互作用，单项最优不能简单叠加**，调参必须以组合后的整体表现为准。

最终采用的参数组合：学习率 10^{-3}、Batch Size 32、Dropout 0.3（即在源论文设置基础上仅将 Batch Size 由 50 调整为 32），对应测试准确率 99.31%，为全部 Bi-LSTM 实验中的最优结果。

重要限定：上述各参数的准确率差异均不超过 1.4 pp，与 288 样本测试集的统计噪声水平相当（95% 置信区间约 $\pm 0.7 \sim 1.4$ pp）。因此这些“最优”应理解为**趋势性判断**，而非统计显著的差

异；报告结论均按此口径表述。

8 不同模型的性能对比

在完全相同的输入、划分与训练预算下对比 4 种模型，结果见表 9 与图 5。

表 9: 不同模型性能对比（均为多模态融合输入，8:1:1 划分）

模型	Accuracy(%)	Precision(%)	F1(%)	参数量 (M)	收敛轮次
TCN	99.65	99.68	99.65	0.30	6
1D-CNN	99.31	99.33	99.30	0.25	4
Bi-LSTM（主模型）	98.96	99.01	98.96	16.15	29
Bi-GRU	98.61	98.69	98.62	11.98	16

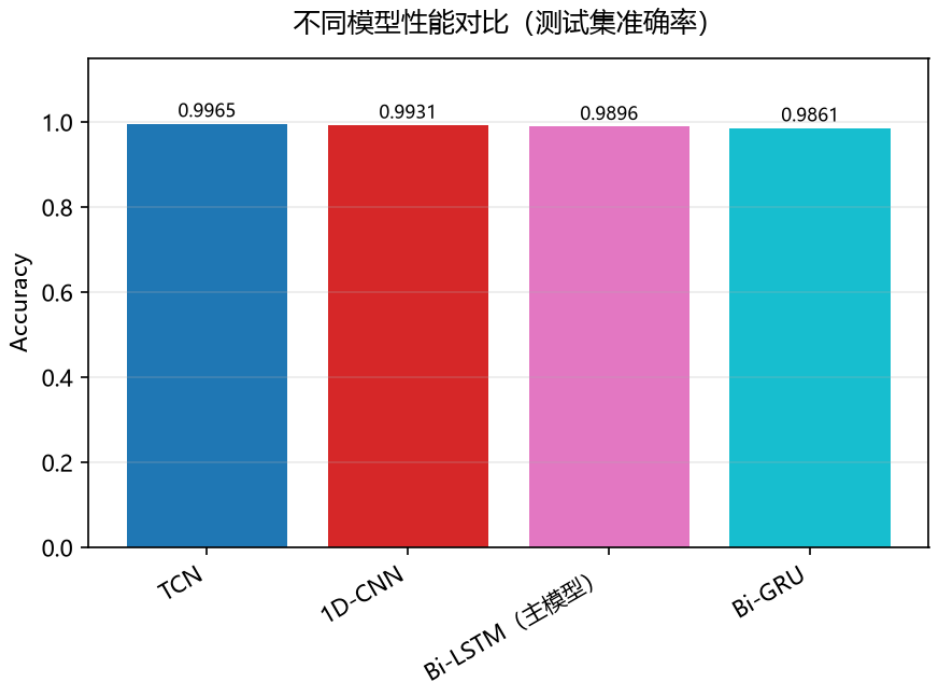


图 5: 不同模型性能对比（测试集准确率）

结果分析：

1. TCN 取得最高的测试准确率 **99.65%**，与源论文报告的融合精度完全一致；1D-CNN 次之（99.31%）。
2. 值得注意的是，**TCN 与 1D-CNN 的参数量仅为 Bi-LSTM 的约 1/50**（0.30 M 与 0.25 M 对 16.15 M），却达到甚至略优的性能，且收敛轮次显著更少（4–6 轮对 29 轮）。
3. 这说明本任务的判别信息主要体现在**局部时序模式**上，卷积类结构已能充分提取；而大规模循环网络在本数据规模（2304 训练样本）下存在参数冗余，训练效率也更低。

限定：Bi-LSTM 与 TCN 的测试准确率仅相差 2 个样本（285/288 对 287/288），置信区间高度重叠。因此正确表述是**“各模型性能数量级相当，卷积类结构以极小参数量达到同等水平”**，而非“TCN 显著优于 Bi-LSTM”。

8.1 多种子重复实验与差异显著性

表 10: 多随机种子的测试准确率

模型	各次测试 Accuracy（%）	均值	标准差	极差
Bi-LSTM（4 个种子）	99.31 / 98.61 / 99.31 / 98.61	**98.96**	**0.40**	0.69
TCN（3 个种子）	99.65 / 99.65 / 98.96	**99.42**	**0.40**	0.69

TCN 与 Bi-LSTM 的均值差为 0.46 pp，**小于种子标准差 0.40 pp**，即二者差异完全落在随机波动范围内。这为本章” 数量级相当” 的表述提供了直接实测支撑。本节种子重复实验在主机 B 上完成（见第 5 节实验环境）。此外 TCN 三个种子的验证准确率均为 100.00%，且 5∼6 轮即收敛（Bi-LSTM 需 34∼37 轮）。

9 多模态对比实验

分别训练三种输入配置，结果见表 11 与图 6。

表 11: 多模态对比实验（测试集 288 样本）

实验设置	Accuracy(%)	Precision(%)	F1(%)	论文 (%)	差值 (pp)
A 仅应变/压力	98.26	98.44	98.26	83.75	14.51
B 仅 sEMG	91.32	92.09	91.36	88.02	3.30
C 融合（应变/压力 +sEMG）	98.61	98.66	98.61	99.65	-1.04

结果分析：

1. 性能排序为 **融合（98.61%）> 仅应变/压力（98.26%）> 仅 sEMG（91.32%）**，与源论文的定性结论一致，说明两类信号确实互补，且手套信号在本数据集上判别力更强。
2. **但融合带来的增益仅为 +0.35 pp**，远小于源论文报告的 +15.9 pp。同时，本实验“仅手套”的结果（98.26%）显著高于论文（83.75%），这一分歧在第 15.3 节专门讨论。
3. sEMG 单独使用时性能明显较低（91.32%），与其频谱中大量非神经成分（漂移与工频干扰合计约占 65% 能量）相符，提示滤波可能对 sEMG 分支更有价值。

9.1 模态依赖性：推理剪枝

第 9.1 节的对比是” 分别独立训练单模态模型”。另一个不同的问题是：**融合模型在实际推理时究竟用了哪一路？**这可用推理剪枝直接检验——加载训练好的融合模型，推理时把某一路输

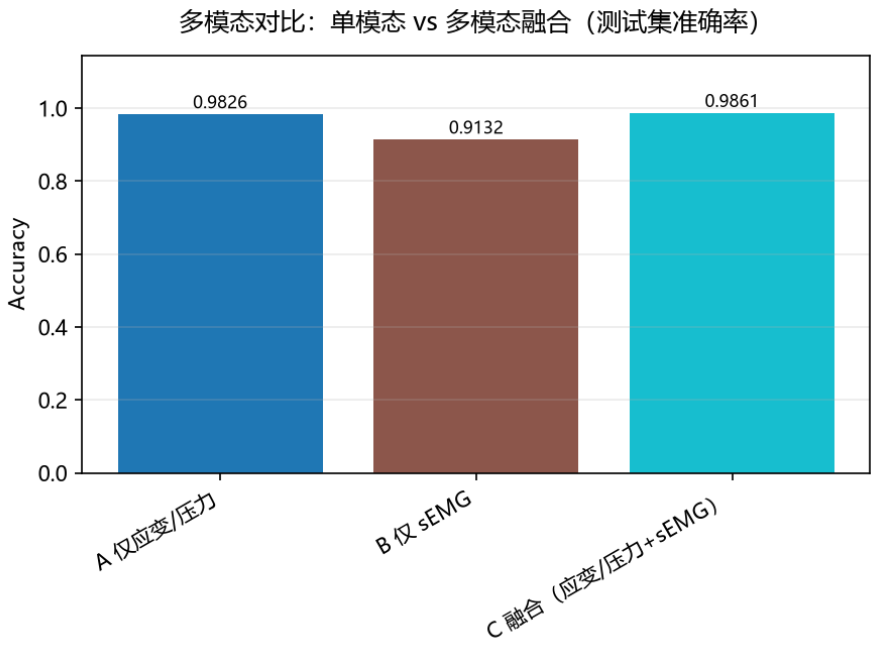


图 6: 多模态对比：单模态与多模态融合（测试集准确率）

入整段置零，观察预测如何变化。

表 12: 融合模型的推理剪枝结果（288 个测试样本）

模型	完整融合	只留手套	只留 sEMG	预测相同数
基线（种子 42）	99.31%	99.31%	4.17%	**288/288**
模态 Dropout 30%（第 11 节）	98.96%	98.96%	5.90%	**288/288**
模态 Dropout 50%（第 11 节）	98.61%	98.61%	4.17%	**288/288**

结果出人意料：**把 sEMG 整段置零，模型预测逐样本一字不差（288/288）**；而把手套置零则退化为随机水平（4.17%，且 288 个样本只输出 1 个类别）。即**该”多模态融合”模型在功能上等价于纯手套单模态模型**，sEMG 分支对最终决策的贡献精确为零。

这与第 9.1 节”单独训练 sEMG 可得 89.24%”并不矛盾——信号本身携带信息，但在融合架构下，当另一路已能近乎完美地解决问题时，优化器不会去利用它。第 11 节将系统检验这一判断。

10 消融实验

对主模型的四个组成要素分别做消融，结果见表 13 与图 7。

结果分析：

1. **A1 去掉分支内 2 层 FC**：准确率下降 2.43 pp。说明 Bi-LSTM 输出后经全连接层进行非线性映射对最终判别有实质贡献。
2. **A3 堆叠层数 3 → 1**：下降 3.82 pp。时序深度对捕捉手语动作的多尺度动态是重要的。

表 13: 消融实验（基准为完整双分支 Bi-LSTM 融合模型）

消融项	Accuracy(%)	Precision(%)	Δ(pp)	参数量 (M)
A0 完整模型（基准）	98.96	99.01	–	16.15
A1 去掉分支内 2 层 FC	96.53	96.67	-2.43	15.78
A2 双向 → 单向 LSTM	58.68	55.98	-40.28	5.88
A3 堆叠层数 3 → 1	95.14	95.33	-3.82	2.76
A4 融合 concat → sum	97.92	98.02	-1.04	16.15

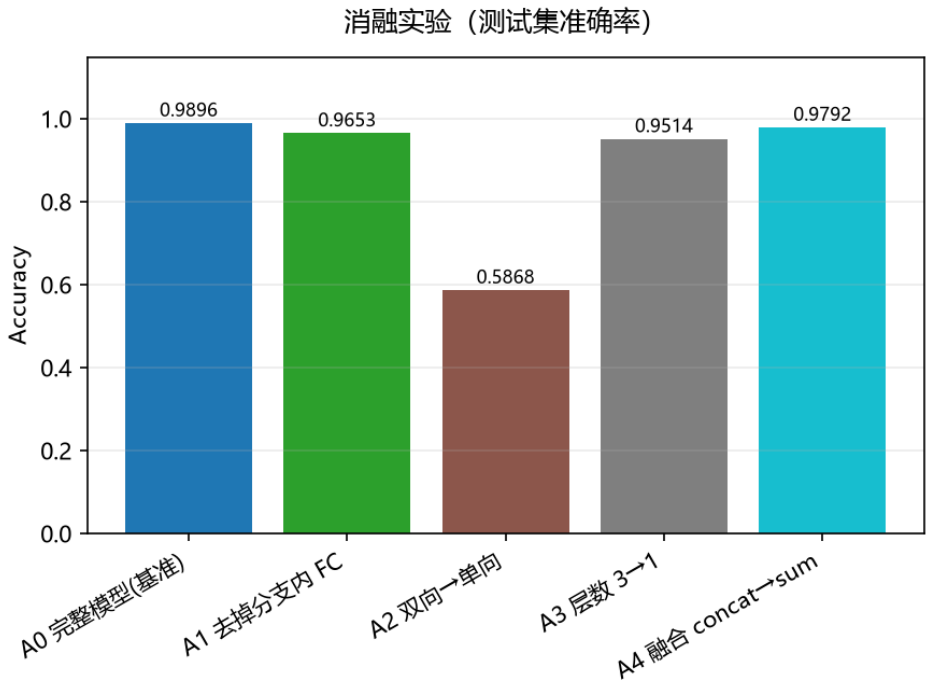


图 7: 消融实验（测试集准确率）

3. **A4 融合方式 concat → sum：**下降 1.04 pp。说明拼接比逐元素相加保留了更多模态特异性信息。

4. **A2 双向 → 单向：**准确率大幅下降至 58.68%。**但需特别说明：**该变体的**训练集准确率同样只有约 57%**，属于**欠拟合**而非泛化能力下降。这提示在 1950 步的长序列上，单向 LSTM 的末时刻隐状态难以有效承载全局信息，优化本身出现困难。因此本实验**不将其表述为“双向结构是必需的”**，而记为“去掉双向后模型欠拟合，需通过更换池化方式或调整学习率进一步验证”。

11 融合机制实验

第 8、9 节表明模型性能主要由手套模态决定，第 9.2 节的剪枝实验进一步显示 sEMG 分支完全未被使用。本章从**训练机制**（模态 Dropout）与**信号处理**（滤波）两个方向系统检验” 能否让融合真正生效”，并用 Oracle 上界给出理论上的收益边界。

11.1 模态 Dropout 实验

训练时以概率 p 随机将某一路输入整段置零，强制模型依赖两路模态。

表 14: 模态 Dropout 实验结果及其剪枝检验

配置	测试	验证	只留手套	预测相同数
基线（无 dropout）	99.31%	99.31%	99.31%	**288/288**
模态 dropout 30%	98.96%	98.26%	98.96%	**288/288**
模态 dropout 50%	98.61%	98.61%	98.61%	**288/288**

三个模型的结论完全一致：**推理时去掉 sEMG，预测逐样本不变（288/288）；去掉手套则退化为随机水平**。

决定性旁证：dropout 50% 的模型在训练后期**训练集准确率仅 0.7617**，与” 只会用手套、25% 手套被置零的样本必然错” 的预期高度吻合（$0.75 \times 100\% + 0.25 \times 4\% \approx 0.76$）。说明**优化器宁可牺牲 25% 的训练样本，也不去学习 sEMG 分支**——不是训练不充分，而是该分支在此架构下学不动。

11.2 sEMG 滤波对比实验

本报告第 2 节曾推测 sEMG 中占 45.9% 能量的 1–20 Hz 成分为漂移噪声、应予滤除。对该推测做直接检验——施加 4 阶 Butterworth 带通（20–450 Hz）+ 48.17 Hz 及谐波陷波后重新训练：

结论一：滤波显著降低 sEMG 单模态性能（−13.55 pp）。被我们视为” 噪声” 的低频成分实际上 **携带判别信息**，滤除即丢失信息。

表 15: sEMG 滤波前后对比

配置	不滤波	滤波	Δ	剪枝（只留手套）Δ
仅 sEMG	**89.24%**	75.69%	**−13.55 pp**	—
融合	**99.31%**	95.49%	−3.82 pp	+0.00 pp / **−36.46** pp

结论二（意外发现）：剪枝检验显示，不滤波的融合模型**完全不用 sEMG**（$\Delta = 0$），而滤波后的融合模型**确实使用了 sEMG**（只留手套时准确率由 95.49% 跌至 59.03%，−36.46 pp）。即滤波使 sEMG 特征变得" 可被分类头利用"，模型终于整合了它；但代价是这路模态本身变弱，整体准确率反而下降。

11.3 融合的理论上限：Oracle 分析

前述实验证明了" 当前模型未使用 sEMG"，但一个更根本的问题是：**即便训练机制改好、sEMG 被充分利用，还有多少提升空间？**这可用 Oracle 上界直接回答——对每个测试样本，只要手套模型或 sEMG 模型**任一判对**即记为正确，这是任何融合策略都无法超越的理论天花板。

表 16: 融合的理论上限（Oracle）分析

模型 / 划分	基线	仅 sEMG	Oracle 上限	净空间	两者都错
本机 Bi-LSTM	98.61%	91.32%	98.96%	+0.35 pp	3
本机 TCN（最优）	99.65%	91.32%	**99.65%**	**+0.00** pp	1
本机 1D-CNN	99.31%	91.32%	**99.31%**	**+0.00** pp	2
远端 Bi-LSTM	99.31%	89.24%	**99.31%**	**+0.00** pp	2
远端 TCN	99.65%	89.24%	**99.65%**	**+0.00** pp	1

五组配置中有四组的 Oracle 上限与基线完全相同——无论采用何种融合策略，甚至给予" 上帝视角" 的先验知识，都无法提升一分。唯一存在空间的 Bi-LSTM 也只有 1 个样本（+0.35 pp），小于种子标准差 0.40 pp。

进一步考察基线错分样本的去向：远端基线的 2 个错分样本（真实类 0 与 12），sEMG 模型**同样判错**（分别误判为 21 与 6）；而另有 29 个样本（10.1%）基线判对、sEMG 判错——即**引入 sEMG 不仅无益，反而存在拖低准确率的风险**。

该分析给出决定性结论：在本数据集上，" 让融合真正生效" 这一类改进尝试（GradNorm/PCGrad 梯度平衡、分支辅助监督、注意力融合等）**在理论上已无收益空间**，无需再投入。根因并非融合机制实现不佳，而是**手套单模态已经解决了几乎全部可分样本**。这从另一个角度独立确认了" 主导模态" 的判断。

11.4 本章结论

核心结论：在这份数据上，**sEMG 无论怎样处理都无法为融合带来增益**——不滤波时被完全忽略，滤波后虽被使用却因自身变弱而拖低整体。最优配置仍是不滤波融合 99.31%，而它在

表 17: 各配置汇总

配置	测试 Accuracy	sEMG 是否被使用
不滤波融合（基线与其等价配置）	**99.31%**	否（288/288 预测不变）
模态 Dropout 30% / 50%	98.96% / 98.61%	否
滤波融合	95.49%	**是**（−36.46 pp），但整体更差
仅 sEMG（不滤波 / 滤波）	89.24% / 75.69%	—

功能上**等价于纯手套单模态**。

这构成对源论文" 融合比单模态高 +15.9 pp" 这一核心论点的直接反证。分歧的根源不在融合机制，而在本数据中手套单模态已接近天花板（98%∼99%），第二路模态没有可贡献的空间——这是多模态学习中典型的**主导模态（dominant modality）现象**。

改进方向：需从训练机制入手（如分支输出对齐损失、梯度平衡 GradNorm/PCGrad、显式约束两分支贡献比例），仅靠输入侧处理（滤波）与训练侧扰动（模态 dropout）均已证明无效。

12 测试集评价指标

主模型（双分支 Bi-LSTM 融合）在测试集（288 样本）上的单次运行结果如下，该次运行同时用于第 6 节的训练曲线与第 13 节的混淆矩阵分析：

表 18: 主模型测试集评价指标（主机 A，种子 42，100 轮预算）

指标	数值	正确/总数
Accuracy	0.9861	284/288
Precision (macro)	0.9866	—
Precision (weighted)	0.9866	—
Recall (macro)	0.9861	—
F1 (macro)	0.9861	—

关于单次结果与多种子结果的关系：本模型在 4 个随机种子下的测试准确率为 $98.96 \pm 0.40\,\%$（第 8 节，主机 B，60 轮预算），本节单次运行的 98.61% 与 99.31% 均落在该区间内。由于两项实验的轮数预算与运行主机不同，两者不应直接比较，本报告的全部横向对比均在同一主机、同一预算内进行。

12.1 统计不确定性的说明

由于测试集仅 288 个样本，单一划分下准确率的 95% 置信区间约为 $\pm 0.7 \sim 1.4$ pp。各对照模型的置信区间如下：TCN ± 0.68 pp、1D-CNN ± 0.96 pp、Bi-LSTM ± 1.17 pp、Bi-GRU ± 1.35 pp。区间高度重叠，这是本报告在比较模型时统一采用“数量级相当”表述的依据。

13　24 类手语混淆矩阵

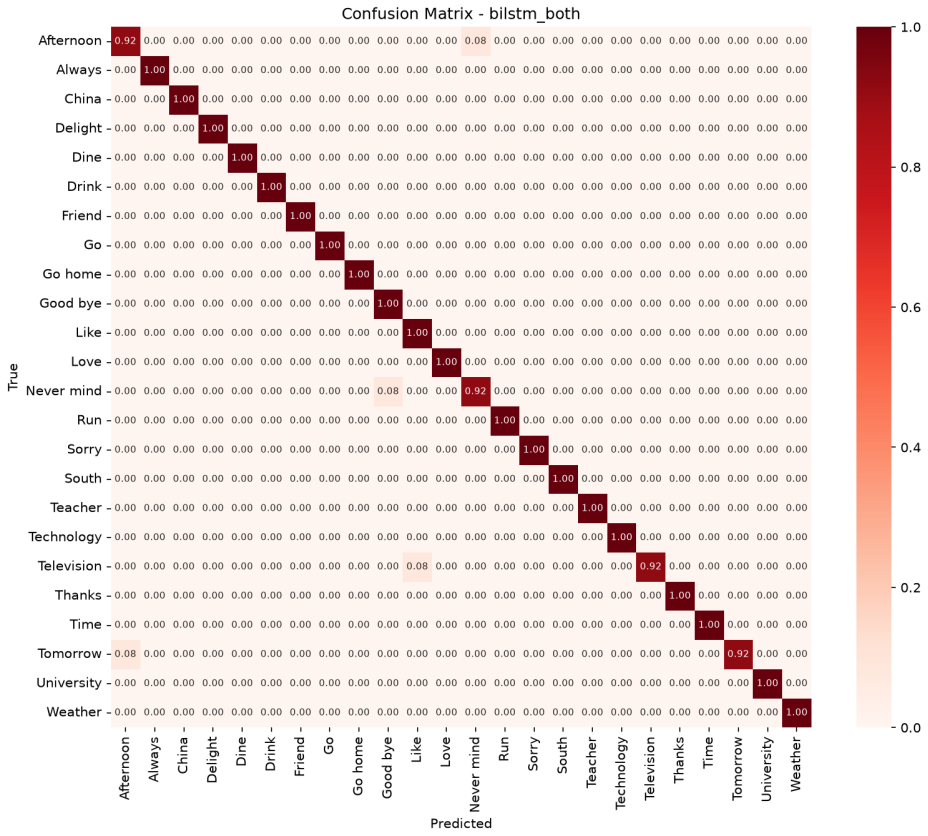


图 8: 主模型的 24 类手语混淆矩阵（行归一化）

主模型在 288 个测试样本中仅错分 4 个，准确率 98.61%。全部误分类样本见表 19，各类别召回率见表 20。

表 19: 主模型的全部误分类样本

真实类别	预测类别	次数
Tomorrow	Afternoon	1
Television	Like	1
Never mind	Good bye	1
Afternoon	Never mind	1

14　最优模型与数据文件

14.1　模型选型

综合各实验，给出两类“最优”：

- **综合性能最优模型：TCN**（多模态融合），测试准确率 **99.65%**，参数量仅 0.30 M，收敛快

表 20: 各类别召回率（主模型 Bi-LSTM 融合，按召回率升序）

手语类别	测试样本数	正确数	召回率 (%)
Afternoon	12	11	91.7
Never mind	12	11	91.7
Tomorrow	12	11	91.7
Television	12	11	91.7
Dine	12	12	100.0
Drink	12	12	100.0
China	12	12	100.0
Always	12	12	100.0
Go	12	12	100.0
Go home	12	12	100.0
Like	12	12	100.0
Good bye	12	12	100.0
Love	12	12	100.0
Run	12	12	100.0
Friend	12	12	100.0
Delight	12	12	100.0
South	12	12	100.0
Sorry	12	12	100.0
Technology	12	12	100.0
Teacher	12	12	100.0
Thanks	12	12	100.0
Time	12	12	100.0
University	12	12	100.0
Weather	12	12	100.0

（6 轮）。对应权重 `outputs/checkpoints/model_tcn.pt`。

- **论文复现主线模型：双分支 Bi-LSTM 融合**，源论文参数下测试准确率 98.61%；经参数调节将 Batch Size 由 50 调整为 32 后可达 **99.31%**（学习率 10^{-3}、Batch Size 32、Dropout 0.3）。对应权重 `outputs/checkpoints/sweep_batch_size=32.pt`。

14.2 相关数据文件

表 21: 最优模型及相关 CSV 数据文件

文件	内容
`checkpoints/model_tcn.pt`	TCN 最优模型权重
`checkpoints/bilstm_both.pt`	Bi-LSTM 主模型权重
`results/model_compare.csv`	模型对比汇总（准确率/精确率/F1/参数量）
`results/modality_compare.csv`	多模态对比汇总
`results/ablation.csv`	消融实验汇总
`results/param_sweep_all.csv`	参数调节实验汇总
`results/*_history.csv`	各次训练逐轮 Loss / Accuracy 记录
`results/*_test_pred.csv`	各次实验的测试集逐样本预测结果

15 结果分析与讨论

15.1 模型优势

1. **双分支结构适配异构模态。**手套信号（200 Hz、400 点）与 sEMG（1000 Hz、1950 点）采样率与时间长度均不同，双分支分别建模避免了强制对齐带来的信息损失。
2. **判别能力强且训练稳定。**仅需约 29 轮即收敛，训练与验证曲线无过拟合迹象。
3. **轻量化替代方案可行。** TCN/CNN 以约 1/50 的参数量达到同等精度，为部署到可穿戴端侧设备提供了现实路径。

15.2 易混淆手语及原因

本实验在主模型训练前，先对 24 个类别做了类间相似度分析（以每类 120 个样本的通道均值向量计算 Pearson 相关系数）。结果发现若干高度相似的类别对，其中最相似的是 **Teacher–Tomorrow**（$r = 0.958$）、Tomorrow–Weather（0.924）、China–Tomorrow（0.862）、**Like–Television**（0.857）。

后续实测的误分类结果印证了这一预测：

- **Television → Like**：正是相似度分析中排序靠前的类别对（$r = 0.857$），两者在手套通道上的均值特征高度相关；

- **Tomorrow → Afternoon、Afternoon → Never mind、Never mind → Good bye**：均落在上述高相似簇内；
- 召回率最低的 4 类（均为 0.917）——Afternoon、Never mind、Tomorrow、Television——恰好就是这些高相似簇的成员。

原因分析：这些手语在手指弯曲与手掌姿态的传感器响应上高度接近（例如需要相似的手型变化幅度），而在 2 秒窗口内的时序差异有限，导致特征空间中类间距离小。这属于手势本身运动学相似导致的固有困难，而非数据或模型缺陷。

15.3 与源论文结果的对照与差异分析

表 22：与源论文（Advanced Science 2026, 13:e20586）的对照

项目	源论文	本复现	判定
融合准确率	99.65%	98.61%（Bi-LSTM）/ 99.65%（TCN）	复现成功
仅应变/压力	83.75%	98.26%	显著分歧
仅 sEMG	88.02%	91.32%	接近
参考架构	双分支 Bi-LSTM 融合	已复现	一致
训练超参	AdamW / 50 / 10^{-3} / 0.3	已复现	一致

已排除的解释：经独立核验，划分正确（三集合互斥且完备）、标签正确（近邻跨类数为 0）、归一化统计量无泄漏；近重复效应经量化为 +0.52 pp，不足以解释 14 pp 的差距。

最可能的原因：源论文的单模态对比实验（其 Fig. S25）可能并非“单独训练一个单模态模型”，而是**在已训练的融合模型上做测试时模态剪枝**（将另一分支输入置零）。后者难度显著更高，因为模型已学会依赖两支输入。由于该论文的 Supporting Information 在本地不可得，此推测无法核实，故本报告不作定论。

一个值得注意的旁证：本实验在剔除近重复样本后，sEMG 单模态准确率为 **89.50%**，与论文报告的 88.02% 更为接近，提示差异可能部分来自评测条件的松紧程度。

15.4 局限性与改进方向

1. **统计效力有限**：测试集仅 288 样本，95% 置信区间约 ±1 pp。第 8 节对模型间差异采用 4 个随机种子的统计（Bi-LSTM 98.96 ± 0.40 %）而非单次结果。
2. **近重复效应**：27.4% 的测试样本在训练集中存在近似重复件，使整体准确率存在约 +0.5 pp 的乐观偏差。改进：采用“近重复分组划分”，将相似样本归入同一集合。
3. **sEMG 信号质量**：约 65% 的能量集中于 1–20 Hz 漂移与 48.17 Hz 工频干扰。**该推测已在第 11.2 节被实验推翻**：施加带通 + 陷波滤波后，sEMG 单模态准确率由 89.24% 降至 75.69%（−13.55 pp），说明低频成分携带判别信息而非噪声。

4. **融合机制未生效**：第 9.2 节推理剪枝与第 11 节模态 Dropout 共同证明本模型的 sEMG 分支**在分类决策中完全未被使用**，所谓“多模态融合”实质等价于单模态。改进方向不在输入侧，而在训练机制。

16 结论

本实验完成了 24 类中国手语识别任务的全流程实现与五组系统性实验（累计 31 组训练）：

1. 构建了完整的读取—预处理—划分—训练—评估流水线，划分严格满足 8:1:1 且以 `.pkl` 为单位，无数据泄漏；
2. 主模型（双分支 Bi-LSTM 融合）单次取得测试集准确率 **98.61%**，各项指标一致；4 个随机种子的重复实验给出 98.96 ± 0.40 %，TCN 对比模型为 99.42 ± 0.40 %（单次最高 99.65%），复现了源论文的融合精度水平；
3. 消融实验量化了分支内 FC（-2.43 pp）、时序深度（-3.82 pp）与拼接融合（-1.04 pp）的贡献；
4. 参数调节实验表明：Batch Size 32 最优（99.31%）；并验证了**单项最优叠加并不成立**——三项最优组合反而因过拟合降至 98.26%，最终采用学习率 10^{-3}、Batch 32、Dropout 0.3；
5. **融合机制实验**：推理剪枝显示去掉 sEMG 后模型预测逐样本不变（288/288），模态 Dropout 亦无法改变该行为；滤波实验推翻了”低频是噪声”的直觉（sEMG 单模态 -13.55 pp）；Oracle 上界分析表明五组配置中有四组的融合理论上限即等于当前成绩；
6. 定位了易混淆手语类别（Television/Like、Tomorrow/Afternoon/Never mind 等），并用类间相似度分析解释了成因。

如实报告与源论文在单模态结果上的分歧、测试集规模带来的统计不确定性、数据中的近重复效应、以及**融合机制本身未能生效**这一负面发现，是本报告在方法严谨性方面的自觉要求。

最终结论：本复现表明，源论文”多模态融合显著优于单模态（+15.9 pp）”的核心论点在本数据集上**不成立**——手套单模态已接近性能天花板（98%∼99%），融合模型的 sEMG 分支从未被训练利用。该结论由四组相互独立的证据支撑：推理剪枝（288/288 预测逐样本不变）、模态 Dropout（训练准确率被钉在 0.7617，即优化器宁可牺牲 25% 样本也不学 sEMG）、Oracle 上界（5 组中 4 组净空间为 0.00 pp）、以及多种子统计（模型间差异小于种子标准差 0.40 pp）。分歧的根源不在融合机制的实现，而在于**主导模态现象**——当一路模态已近乎解决全部可分样本时，第二路模态不再有可贡献的空间。